E1 预计交付日期模型改进实验方案

Oct 15, 2026 · @geniussuzane

状态：配置 v3 已保存并登记哈希，v1、v2 保留在变更记录里。已完成 F0 / V 候选拟合与设定选择（C* = C0，即未选中任何线性改动；D* = D3，深度 2、400 次迭代），并用一次独立登记的复现运行逐项重现。随后已按登记顺序在 F 上拟合、在 C 上校准、写入冻结记录，并在 E 上评价一次（2026-10-20）；结果见《E1 研究思路》文档。检查点 2 曾按旧设定重新拟合 B2，仅用于复现一致性检查。

> 当前登记：`config/date_model_e1.yaml` v3，SHA-256 `ae6a4a4664c82124399d9da38354376955e6e783fd720eece608ac801eb20152`（2026-10-16 17:06 UTC）。先前版本：v2 `fc1413b8…259fe`、v1 `a4898f11…8cfe`。v2 加入执行规则，v3 统一 H1 / H2 判定、平局规则和“无法评价”状态；模型、切分、网格和阈值都没有变，每次改动时都尚未拟合新模型。变更记录见 `docs/E1_DECISIONS.md`。

实验决策表

每一行都在看到任何新结果之前写定。选择规则只决定“选谁”；结论规则决定“怎么说”，两者分开。

问题	比较对象	参照	主指标	阈值	选择 / 平局规则	结论表述
选线性设定	C0 → C3	前一步	V 上整数日 pinball（q = 0.90）	相对降低 ≥ 1% 才采纳	平局集合 = 所有 L ≤ 1.001 × 全局最小 L 的候选；集合内取更大 α	有限的逐步搜索，可能漏掉“两个改动一起才有效”的组合，不是最优模型的证明
选 HGB 设定	D1–D8	—	同上	取最小	平局集合同上；集合内先取更浅，再取更少迭代	同上
H1	R0 → R3 逐步	主判断只看 R3 对 R0；R1、R2 只作描述，不单独触发 H1	回归与州规则的天数差、覆盖率差、判定	变化 ≥ 0.5 天或 ≥ 0.5 个百分点，或判定改变	—	未达阈值时写“在本次预先指定的逐步比较中，没有发现达到实际意义阈值的变化”

问题	比较对象	参照	主指标	阈值	选择 / 平局规则	结论表述
H2	C* 对 B3，均未校准	B3	E 上 Δ pinball	g = (L_B3 − L_C*) / L_B3 ≥ 2%，且 Δ = L_C* − L_B3 的区间上端 < 0	—	达到预设标准 / 有潜在价值但证据不足 / 未达到实际意义标准
H3（公平比较）	D* + C 平移	B1c：州规则 F + 同一 C 平移	1 天 / 1 点；月度可靠性	至少短 1 天、覆盖率最多低 1 点、无月份低 3 点以上	—	“在统一条件下是否带来额外价值”
是否替换现有规则	C*、D* + C 平移	项目保留的旧州规则（F + C 拟合，不平移，q = 0.90）	同上	同上	—	与公平比较分开报告，例如“优于统一条件下的州基线，但尚未优于原有策略：支持继续研究，不支持替换”
与 Olist 对照	M 运行（q = 0.9126）	Olist 原日期	同上	同上	—	写“以校准期 Olist 覆盖率为目标”；目标相同不等于评价期覆盖率相同

第二个参照很重要：统一训练数据可能让基线变弱。新模型超过变弱的基线，不等于项目取得了实际改进。若某个模型族的候选全部拟合失败，或主要比较所需的预测、指标、区间无法有效计算，结果记为“无法评价”，不记为假设不支持，也不临时换用未登记的替代模型。

已核实的现有实现

版本与路径。 你已核对本机 ZIP 与我生成的 v0.6.3 一致。完整 SHA-256 `11ba652c9b77f12bb6b7f296edf03badeb8cf541c0d94897bba12421c826a41c` 将写入实验记录。实验在新的工作副本中进行，v0.6.3 的文件、配置和注册哈希都不改。

从代码核实到的事实（`run_stage7.py`、`date_policy.py`、`features.py`、`config/date_policy.yaml`）：

项目	实际实现
按州规则的训练数据	拟合期 + 较早校准期（25,666 + 17,056 单），不做校准平移
回归的训练数据	仅拟合期（25,666 单）；再用较早或近期校准期计算单侧平移

项目	实际实现
卖家历史快照	拟合行：下单月月初更新；较早校准行：统一冻结在 2017-10-01；近期校准行：2018-01-01；评价行：统一冻结在 2018-04-01
快照的标签规则	只用快照时刻前已签收的订单（按签收时间而非下单时间筛选），并有异常检查
回归设定	线性 `QuantileRegressor`（HiGHS，α = 0，无正则化），目标为 log1p(配送天数)，11 个数值 + 2 个类别特征
星期几	`purchase_dow` 作为 0–6 的连续变量，只做标准化
预处理	在拟合行上拟合；州编码 `min_frequency = 300`

诊断指标复算。 从 `outputs/stage7/orders/evaluation_promises.csv`（19,950 单）独立重算 90% 日尺度 pinball loss，用的是整数预计天数：按州规则 1.4827，未校准回归 1.3892，较早窗口校准 1.5761，近期窗口校准 1.5613，与你给的数一致。未取整的回归预测为 1.4016。这些是事后补算的诊断，不改变旧研究的判断，也不是旧研究的预设指标。

已确认的问题与待验证假设

三个比较设计问题都在代码里得到了确认。

问题 1：训练数据不一致。 历史比较里，按州规则多用了 17,056 张更新、延误率更高（8.74%）的第四季度订单；回归只用拟合期，再靠平移补偿。旧的“回归 vs 州规则”差异因此混入了数据新鲜度。新实验里两者只用同一拟合集，并分别比较：(a) 未校准预测器；(b) 用同一校准集平移后的完整策略。旧策略保留为历史参考。

问题 2：快照口径不一致。 拟合行的卖家历史按月更新，校准行和评价行却冻结在窗口起点。评价期末的订单因此用的是最多早 3.5 个月的历史。新规则 U：每张订单使用下单月月初已知的卖家历史，只计月初前已签收的订单。这使评价期变成“模型参数冻结、历史特征按月更新”，是一个新的策略设计。旧的完全冻结方案（O）保留并单独报告，不替换。

问题 3：样本选择（不换人群）。 人群是预计交付周在获批窗口内（2017-02-27 至 2018-07-23）、最终按时或延误、单卖家的订单：99,441 → 86,729 → 84,129 → 83,063。是否入样取决于最终签收，这是下单时不可知的信息。所以估计对象是“最终签收订单中的条件覆盖率”，不是全部下单订单的覆盖率。末期变薄：2018-07 只有 1,085 单。未确认订单 U 与取消／不可用订单 X 不当作删失，本轮也不建模。我不建议本轮改成按下单日期构造的队列：那需要重新处理 U 和 X（X 没有可用时间戳），估计对象会变，旧结果也无法对比。如果你希望做，可以单独立一轮。

H1 的逐步对照。 新比较同时改变了三件事：州规则的训练样本、州规则是否校准、回归的快照口径。所以每次只改一件，每一行都报告“回归策略 − 州规则策略”的天数差、覆盖率差与 1 天 / 1 点判定。所有行都在冻结后统一评价。

对照	州规则	回归策略	与上一行相比唯一的改变
R0 历史	F + C 拟合，不平移	O 快照，C 平移	原始参考（回归多 2.57 天、覆盖率高 2.50 点）
R1	只用 F，不平移	同 R0	州规则的训练样本
R2	只用 F，C 平移	同 R0	基线的校准方式
R3	同 R2	U 快照，重新计算 C 平移	特征更新策略

R0 里的回归与新实验的 B2 设定完全相同，所以 B2 必须逐单复现旧的未校准回归与较早窗口校准结果；这是一项测试。逐步分解取决于改变的顺序，只作描述。

三个假设。

假设	主要比较	主要指标	判定
H1 统一数据和快照后，回归与州规则的差异会改变	主判断只用 R3 对 R0；R1、R2 的相邻比较只作描述，不单独触发 H1	策略层天数差、覆盖率差与 1 天 / 1 点判定；预测层 pinball 差	支持：判定与 R0 不同，或天数差变化 ≥ 0.5 天，或覆盖率差变化 ≥ 0.5 个百分点。不支持：在本次指定对照与阈值下，没有观察到足够大的差异变化；不能排除因素之间的抵消或其他设计影响

假设	主要比较	主要指标	判定
H2 简单编码或正则化能改善回归的时间外分位数预测	C* 对 B3：同一 F、同一 U 快照、未校准	Δ = loss(C*) − loss(B3)，评价集 90% pinball（整数天）	记 g = (L_B3 − L_C*) / L_B3（相对改善，用于阈值），Δ = L_C* − L_B3（绝对差，其配对区间用于证据）。(1) g ≥ 2% 且 Δ 的 95% 区间上端 < 0：达到预设改善标准。(2) g ≥ 2% 但区间上端 ≥ 0：点估计达到标准，证据不足。(3) g < 2%：未达到实际意义标准。“验证集上未选中任何改动（C* = C0）”另行记录。例：损失从 1.500 降到 1.475，绝对下降 0.025，但 g = 1.67%，未达到 2%。只有 17 个周簇，区间含 0 不等于证明没有作用。
H3 浅层非线性模型在相同校准流程下提供值得保留的策略改善	D* + C 平移对 R2 的州规则（F + C 平移）	1 天 / 1 点判定；月度可靠性	支持：平均至少短 1 天、覆盖率最多低 1 点，且没有 ≥ 1,000 单的月份低于目标 3 点以上。否则保留州规则

样本、时间切分与信息可用规则

顺序是拟合 → 调参验证 → 校准 → 评价，共两个决策时点：2017-12-01 选设定，2018-04-01 重新拟合、校准并冻结。评价窗口与旧研究相同，但我只拿它与旧结果并列展示，不当作新的盲测。

数据段	下单时间	标签截点	符合人群条件	实际使用	排除（原因：截点前未签收）	延误率（实际使用行）	最晚标签	ID 哈希（前 8 位）	用途
调参拟合 F0	2017-01-07 至 06-30	2017-12-01	13,617	13,616	1	3.89%	2017-11-16	878110e0	拟合候选设定

数据段	下单时间	标签截点	符合人群条件	实际使用	排除（原因：截点前未签收）	延误率（实际使用行）	最晚标签	ID 哈希（前 8 位）	用途
验证 V	2017-07-01 至 09-30	2017-12-01	12,049	12,045	4	3.38%	2017-11-24	3874b514	选设定、残差诊断
最终拟合 F	2017-01-07 至 09-30	2018-04-01	25,666	25,666	0	3.67%	2018-02-05	1342d043	重新拟合选定设定（与旧拟合集相同）
校准 C	2017-10-01 至 12-31	2018-04-01	17,063	17,056	7	8.74%	2018-03-27	33b8c5e7	每个最终策略、每个 q 各算一次平移；n = 17,056
评价 E	2018-04-01 至 07-19	—	19,950	19,950	0	4.26%	2018-10-17	702ce5bd	冻结后每个最终策略只评价一次

完整哈希和购买时间范围在 `outputs/e1/prep/partition_manifest.csv`。E 的“最晚标签”是本样本里最晚的签收记录，不是随访截止日。

互斥要求。 选设定阶段 F0 与 V 不重叠；最终阶段 F、C、E 两两不重叠。不要求 F 恰好等于 F0 + V，因为标签截点后移后，此前未签收的订单可以合法进入 F。任何模型都不得因特征缺失而静默删掉订单：缺失值由预定的填补处理，否则直接报错。

“符合人群条件”指最终签收、落在该下单时间段的订单；“实际使用”指其中在标签截点前已签收、真正进入拟合、验证或校准的订单。延误率的分母是实际使用的订单。若算全部单卖家订单，约 97–98% 已签收，其余是最终未签收或取消的订单，它们不在人群里。评价期各月：4 月 6,670、5 月 6,630、6 月 5,565、7 月 1,085（变薄）。这些数字先在检查点 1 初步计算，检查点 2 已从原始数据重新对账，结果一致（outputs/e1/prep/）。

需要注意的两点：

- 2018 年第一季度（旧的近期校准窗口）不进入本轮。冻结时只有 81% 已签收，已签收部分的延误率是 7.0%，最终却是 13.0%，偏向快速配送。
- V（延误率 3.4%）、C（8.74%）、E（4.26%）的难度不同。在 V 上选中的设定不一定在 E 上也更好；在 C 上算出的平移量也可能再次偏宽。

信息可用规则。

- **特征**：只用下单时固定的字段，加上卖家历史快照。主方案 U 取下单月月初，对照方案 O 沿用旧口径。快照只计快照时刻前已签收的订单。Olist 自己的预计日期不作输入。
- **标签**：每个决策时点只用此前已签收订单的标签。每个截点都会自动检查三件事：快照时刻 ≤ 下单时刻且快照里没有未来标签；拟合和调参标签早于截点；校准标签早于 2018-04-01。
- **局限**：我假设数据里的签收时间戳是当时记录的，不是事后补录。数据里没有入库时间，这一点我无法验证。

实验矩阵与训练次数

主目标分位数为 0.90，约 20 次模型拟合，预计总运行时间少于 30 分钟。每一步只改一件事，失败的运行也保留。

阶段	运行	改了什么	拟合在 / 最终评价在	拟合次数
A 复现	A0	不训练：从逐单文件复算历史策略，并生成样本与排除表	—	0
B 基础对照（H1）	B1	按州规则，只用 F，不平移（R1）	F / E	0（只算分位数）
	B1c	B1 + C 平移（R2）	F, C / E	0
	B2	线性回归注册设定，O 快照（逐单复现旧回归）	F, C / E	1
	B3	同 B2，改为 U 快照（R3）	F, C / E	1
C 线性消融（H2）	C0	注册设定：log1p 目标、星期几连续、α = 0	F0 / V	1
	C1	上一步 + 星期几改类别编码	F0 / V	1
	C2	上一步胜者 + 目标改为原始天数	F0 / V	1
	C3	上一步胜者 + L1 正则，α 取 3 个值	F0 / V	3
	C*	选定设定在 F 上重新拟合	F, C / E	1
D 浅层 HGB（H3）	D1–D8	深度 {2, 3} × 迭代次数 {100, 200, 400, 800}	F0 / V	8
	D*	选定设定在 F 上重新拟合	F, C / E	1
对齐目标	M	C* 与 D* 在 q = 0.9126 下重拟合，沿用已选结构和超参数，只用于与 Olist 对照	F, C / E	2

“拟合在 / 最终评价在”只说明每个运行用哪些数据，不代表执行顺序。执行顺序固定为：

1. 复算历史结果，核对数据与样本表。
2. 只在 F0 / V 上选择线性（C0–C3）和 HGB（D1–D8）设定。
3. 在 F 上拟合所有最终模型（B2、B3、C*、D*、M）。
4. 在 C 上计算所有校准量。
5. 冻结模型清单、参数、预处理、校准量与样本清单，写入哈希。

6. 最后一次性计算所有 E 指标。

所有最终候选冻结之前，不输出任何评价期比较成绩，B 系列中间模型也一样。调试只检查输入、形状和是否有限。冻结记录保存切分与订单 ID 的哈希、特征规则、预处理与选定超参数、最终模型文件、每个 q 的平移量、评分代码哈希和阈值（模板：`docs/E1_FREEZE_TEMPLATE.md`）。打开 E 之前会：核对记录自身的哈希；检查每个字段非空、类型正确；用实际评分输入重算分区 ID 哈希；对照 9 个登记运行逐一检查模型与平移量（缺少的运行必须标为“失败”并写明原因）；在 C 上重算平移量；对整个代码包和库版本取指纹；核对阈值。任一项缺失或被改动就拒绝运行。冻结的是特征更新规则：五月的预测可以用五月 1 日前已签收的四月订单，但任何一单都不能用自己的结局或快照后的标签，也不根据四月成绩改规则。旧的 E 结果已经被看过，这仍是有事前记录的探索性扩展，不是盲测。

消融规则。 线性模型每一步只有在 V 上的整数日尺度 pinball 相对前一步降低 ≥ 1% 时才采纳，否则保留更简单的前一步。C3 先在 3 个 α 中取 V 上最小者（所有 L ≤ 1.001 × 全局最小 L 的候选组成平局集合，集合内取更大的 α），再套用 1% 规则。L1 网格现在固定：log1p 目标取 {0.0001, 0.001, 0.01}，原始天数目标取 {0.001, 0.01, 0.1}（目标尺度大约大 10 倍）。关于对数变换：单调变换下，真实条件分位数可以相应变换；但受限的线性模型在对数尺度和天数尺度上优化的经验损失不同（`QuantileRegressor` 优化的是输入目标尺度上的 pinball loss，可加 L1 惩罚），拟合结果不等价。因此我不预先假定哪个更好，统一用日尺度 pinball loss 比较。

HGB 固定设定。 `HistGradientBoostingRegressor(loss="quantile", quantile=0.9)`，目标为原始天数，`learning_rate = 0.05`，`min_samples_leaf = 100`，`l2_regularization = 1.0`。内部早停关闭（`early_stopping = False`），迭代次数由 V 选择，而不是随机划分的验证集。D* 取 V 上整数日尺度 pinball 最小的候选；所有 L ≤ 1.001 × 全局最小 L 的候选组成平局集合（与遍历顺序无关），集合内优先更浅，再优先更少迭代。州和星期几用原生类别处理，随机种子固定为 20261015。

残差诊断（只在 V 上做）。 按月份、预测时长四分位区间、卖家历史单量（0 / 1–9 / ≥10）三种分组看覆盖率。如果某一分组与整体差距 ≥ 3 个百分点且每组 ≥ 500 单，我会提议一个小型特征组：卖家历史实际配送天数中位数、历史样本量、新卖家标记。历史少于 10 单时，历史中位数向州中位数收缩。这一步以及任何更复杂的校准都要先经你确认，不在上表之内。

指标、保留标准与停止条件

实际意义标准不变：平均预计天数至少短 1 天，覆盖率最多低 1 个百分点，且没有 ≥ 1,000 单的月份低于目标 3 个百分点以上。这条标准分别对两个参照报告，不合并成一个“通过”：公平参照 B1c（同数据、同校准集的州规则）回答“模型有没有额外价值”；替换参照（项目保留的旧州规则）回答“值不值得替换现有规则”。pinball 更低本身不足以让策略胜出。

预测层（比较预测器）。

- 主指标：90% 日尺度 pinball loss，算在整数预计天数上。这样州规则与模型可以直接比较；未取整的版本作为模型间的次要指标。

- 分月份报告；预先指定的分组是评价期 ≥ 300 单的客户州，以及卖家历史单量组（0 / 1–9 / ≥10）。

策略层（比较最终日期）。 覆盖率；平均和中位预计天数；未覆盖订单的平均超出天数及其单量；1 天 / 1 点判定；月度可靠性。评价人群仍是同样的 19,950 单，所以可以和旧结果并列；若人群有任何变化，就不再直接比较。

校准。 沿用单侧残差平移，公式使用对应的目标分位数 q，不写死 0.90：

公式： $s_i = y_i - \hat{y}_i$；$k = \lceil (n+1) \cdot q \rceil$；$\Delta = s_{(k)}$（第 k 小的残差）；$d(x) = \max\{1, \lceil \hat{y}(x) + \Delta \rceil\}$。

- 所有模型共用一个校准接口（`e1_models.shift` / `promise`），不在各模型里分别实现。
- 残差在天数尺度计算：log1p 模型先逆变换，再算残差。先校准，后取整；取整使用 ceil(x − 10^{-9})，避免浮点误差多推一天。州规则的“预测”就是州分位数本身。
- 允许负的平移量，不静默截为 0；如果要求不得缩短，那是另一个要单独命名的策略。
- q 作为参数传入：0.90 与 0.9126 各算各的平移量，不复用。M 阶段沿用已选结构和超参数，不重新搜索。
- n 是标签截点前已知、实际进入校准的订单数（C 为 17,056）。k > n 或任何预测不是有限值时直接报错，绝不用 0 平移继续。

模型选择只在 V 上做，C 对每个最终策略只用一次。即便如此，普通 split conformal 的保证仍要求 C 与 E 的分数可交换；C 延误率 8.74%、E 为 4.26%，所以我只称它为“split conformal 形式的平移”，不声称有覆盖保证（Angelopoulos & Bates）。

不确定性。 模型差异在同一订单上配对计算。区间用按下单周的区块自助法：E 共 17 个下单周（首周只含 4 月 1 日，末两周仅 230 和 77 单），重抽 2,000 次，种子固定。

- 所有模型用完全相同的重采样周序列。抽到一周，就带入该周全部订单，重复抽中的周保留重复权重；再按订单重新计算指标，不先算各周指标再等权平均。
- 主方案：整周有放回抽 17 周。敏感性：连续 2 周的移动区块，起点在第 1–16 周中均匀抽取（不循环），拼接 9 个区块后截取前 17 周。
- 95% 区间取百分位数。它只描述固定模型在这段评价数据上的抽样波动，不包含重新训练、调参和样本筛选带来的不确定性。簇数只有 17，区间只适合辅助判断，不能当作时间稳定性的强证据。

停止条件。

1. 任何未来标签、分区重叠或订单重复测试失败：停止，不产出结果。
2. E 只在 C*、D* 和所有平移量写入冻结记录（含哈希）之后才打开。每个最终策略只评价一次，看到 E 之后不再调任何参数。
3. 若 V 上没有选中任何线性改动（C* = C0），H2 直接记为不支持，但仍报告。HGB 在 V 上即使不如线性，也仍对 E 评价一次，避免“只报好的”。
4. 拟合失败（如求解器不收敛）写入记录；失败本身记为失败；只允许用方案里写好的替代求解器重试一次，并标明是重试，不换其他参数。

5. 新特征组或更复杂的校准，只在你确认后另立一步。

预计修改的文件与待你确认的事项

工作将在从 v0.6.3 复制出的独立副本 `olist063-e1/` 中进行。v0.6.3 本身、`config/date_policy.yaml` 及其注册哈希、第 7 阶段的输出和两份报告都不改。已有函数（`date_policy.py`、`features.py`）只导入使用，不修改。

新文件	内容
`config/date_model_e1.yaml`	本方案的预注册：切分、快照规则、矩阵、网格、阈值、种子；哈希写入 `outputs/e1/PREREGISTRATION_SHA256.txt`
`docs/E1_DECISIONS.md`	之后的任何偏离或修正，带时间和“是否已看到结果”
`src/olist_analytics/e1_data.py`	切分、U / O 快照、样本与排除表
`src/olist_analytics/e1_models.py`	州规则、线性变体、HGB、平移、pinball、周区块自助法
`src/olist_analytics/run_e1.py`	按阶段 A–D 运行；每次运行一个文件夹，内含配置、样本 ID、版本、种子、逐单预测和指标
`tests/test_e1.py`	未来标签被排除、预处理只在训练集拟合、分区不重叠、订单不重复、整数天取整、逐单与汇总对账、HGB 内部早停关闭
`docs/E1_NOTE.md`	检查点 4 的研究说明，含哪些用了现成库、哪些由 AI 协助、哪些代码你需要亲自讲清

线性回归求解器不收敛时，写好的替代方案是 `solver="highs-ipm"`。

请你确认或修改。

- [ ] 阈值：H1 用 0.5 天 / 0.5 个百分点；H2 用 pinball 相对降低 ≥ 2% 且区间不含 0；消融采纳门槛 1%；H3 用原有 1 天 / 1 点。
- [ ] 时间切分 F0 / V / F / C / E，以及不用 2018 年第一季度。
- [ ] 主快照用 U（按月更新的新策略），旧的冻结口径 O 作对照。
- [ ] 主目标只用 0.90；Olist 对齐目标只用于与 Olist 对照。
- [ ] HGB 网格（深度 {2, 3} × 迭代 {100, 200, 400, 800}）和 L1 网格。
- [ ] 不换人群；按下单日期构造队列留作单独一轮。
- [x] ~~本机 ZIP 哈希已核对：与 `11ba652c…826a41c` 一致（审阅方重新计算）。~~