为什么用分位数设定预计日期，以及校准的保证到哪里为止

这份说明回答两个问题。第一，为什么预计日期取配送天数的分位数，而不是平均值。第二，校准后的“覆盖率达标”到底指什么。我会区分三个经常被混在一起的量：校准集上的比例、可交换性下的概率，以及评价期的实际比例。这里用到的都是标准结果：分位数是不对称线性损失的最小点，以及分割保形校准背后的排名论证。我按本项目的形式写出并证明它们，再用到项目上；它们都不是新结论。

1. 不对称损失为什么对应分位数

设实际配送天数为整数 $Y \geq 1$，$\mathbb{E}[Y] < \infty$；预计天数为整数 $d \geq 1$。日期太短造成延误，日期太长留下空等。我用线性损失表示这两种代价：

$$L(d, Y) = c_{\text{late}}\,(Y - d)_+ + c_{\text{slack}}\,(d - Y)_+, \qquad c_{\text{late}}, c_{\text{slack}} > 0.$$

这是代价随天数线性增加的简化假设。记 $R(d) = \mathbb{E}[L(d, Y)]$，$F(d) = P(Y \leq d)$，$q = c_{\text{late}}/(c_{\text{late}} + c_{\text{slack}})$。

命题 1. $d^* = \min\{d \geq 1 :\ F(d) \geq q\}$ 使 $R(d)$ 最小。若 $F(d^*) = q$，则 $d^* + 1$ 同样最优。

证明. 比较承诺 d 天与 $d + 1$ 天。逐单来看，

$$L(d+1, Y) - L(d, Y) = \begin{cases} -c_{\text{late}}, & Y > d, \\ +c_{\text{slack}}, & Y \leq d. \end{cases}$$

取期望，

$$\Delta(d) := R(d+1) - R(d) = c_{\text{slack}} F(d) - c_{\text{late}}\big(1 - F(d)\big) = (c_{\text{late}} + c_{\text{slack}})\big(F(d) - q\big).$$

F 单调不减，所以 Δ 单调不减。对 $d < d^*$，$F(d) < q$，故 $\Delta(d) < 0$；对 $d \geq d^*$，$\Delta(d) \geq 0$。因此 R 在 d^* 之前严格下降，之后不再下降，d^* 是最小点。又 $F(0) = 0 < q$，所以 $d^* \geq 1$。若 $F(d^*) = q$，则 $\Delta(d^*) = 0$，即 $R(d^* + 1) = R(d^*)$。

QED

对单笔订单，用下单时的信息 $X = x$，把 F 换成 $F(d \mid x) = P(Y \leq d \mid X = x)$，最优日期就是条件 q 分位数。取 $c_{\text{late}} = q$、$c_{\text{slack}} = 1 - q$ 时，L 就是分位数（pinball）损失。

这个损失说明了分位数目标的决策含义，但它不等于每个模型的拟合目标。项目中的线性模型在 $\log(1 + Y)$ 尺度上拟合分位数回归，再换回天数；HGB 直接在天数上拟合；模型选择和评价都回到天数尺度。分位数在单调变换下不变，所以两种尺度瞄准的是同一个条件分位数，但有限样本中的拟合目标并不相同。

平均值最小化的是平方损失，它把晚到和空等看成对称的代价。一般而言，平均值并不最小化这里定义的不对称损失；在某些分布下，它可能恰好与最优分位数相同。选择 $q = 0.90$ 等价于假设 $c_{\text{late}}/c_{\text{slack}} = 9$，即晚到一天的代价是多留一天的九倍。这是我选定的目标，不是从 Olist 数据中估计出的真实成本比。

2. 校准：三个不同的“覆盖率”

模型给出的 $f(x)$ 只是估计值，直接使用未必达到目标。因此用独立留出的校准集修正。设 f 已拟合完毕，且没有用到校准集。在 n 个校准订单上计算

$$r_i = Y_i - f(X_i), \qquad k = \lceil (n+1)q \rceil \le n, \qquad s = r_{(k)}, \qquad U(x) = f(x) + s,$$

其中 $r_{(k)}$ 是第 k 小的残差。注意 $Y_i \le U(X_i) \iff r_i \le s$。

第一个量：校准集上的比例，至少 k/n。

命题 2. 对任意数据，$\hat{c}_{\text{cal}} := \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} \mathbf{1}\{Y_i \le U(X_i)\} \ \ge\ \dfrac{k}{n}$。

证明. 按定义，至少有 k 个 r_i 不超过 $r_{(k)} = s$（有并列时可能更多）。由 $Y_i \le U(X_i) \iff r_i \le s$ 即得。

QED

这个不等式不依赖任何概率假设，即使未来配送状况已经改变，它仍然成立。该不等式是按指定校准规则计算后的必然结果；仅满足它，既不能证明实现正确，也不能保证未来订单的覆盖率。例如把平移量错设成 1,000 天，同样会满足它。更直接的实现检查，是独立重算第 k 个残差，再与冻结的平移量核对。

第二个量：新订单被覆盖的概率，至少 $k/(n+1)$。

命题 3. 若 $(X_1, Y_1), \ldots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ 可交换，则

$$P\big(Y_{n+1} \le U(X_{n+1})\big) \ \ge\ \frac{k}{n+1} \ \ge\ q.$$

证明. 因为 f 固定，$r_1, \ldots, r_{n+1}$ 也可交换。随机打破并列后，把 $n+1$ 个残差排序，记新订单残差 r_{n+1} 的名次为 ρ。由可交换性，ρ 在 $\{1, \ldots, n+1\}$ 上均匀分布，所以 $P(\rho \le k) = k/(n+1)$。若 $\rho \le k$，则前 n 个残差中排在 r_{n+1} 之前的至多 $k-1$ 个，故其中第 k 小者不小于 r_{n+1}，即 $r_{n+1} \le s$。因此 $P(r_{n+1} \le s) \ge k/(n+1)$。最后，$k \ge (n+1)q$。

QED

分母是 $n+1$，因为新订单本身也是这 $n+1$ 个可交换样本之一。这个概率是对“抽到哪一份校准集”和“来的是哪一笔新订单”同时取平均。它不保证每个月、每个州都达标，也不保证某一份已观察到的校准集之后的覆盖概率达标。随机打破并列只用于证明，不改变实际算法。

第三个量：评价期的实际比例。

设评价期有 m 笔订单，

$$\hat{c}_{\text{eval}} := \frac{1}{m}\sum_{j=1}^{m} \mathbf{1}\{Y_j \le U(X_j)\}.$$

它是一个观察到的比例，不是概率。如果每笔评价订单都与校准订单可交换，由命题 3 得 $\mathbb{E}[\hat{c}_{\text{eval}}] \ge k/(n+1)$；即使如此，有限的 m 也会带来抽样波动，单次观察可能低于或高于这个值。若可交换性不成立，它只描述这批评价订单本身。

量	能说明什么	不能说明什么
$\hat{c}_{\text{cal}} \geq k/n$（命题 2）	按指定规则计算后的必然结果	实现正确；未来订单也会达到目标
$P(Y_{n+1} \leq U) \geq k/(n+1)$（命题 3）	在可交换性下，对校准集和新订单取平均的覆盖至少为 q	每份校准集、每个州、每个月都达标；C 与 E 的可交换性并未确立，因此不对评价期断言这一保证
$\hat{c}_{\text{eval}}$	冻结策略在这批评价订单上的经验表现	全部订单或未来运营中的可靠性

一个简单反例说明第一个量与第三个量可以完全脱节。模型始终预测 10 天，校准订单也全部在 10 天送达，于是 $s = 0$，$\hat{c}_{\text{cal}} = 100\%$。若未来订单都要 15 天，$\hat{c}_{\text{eval}} = 0$。反过来，若未来订单都只要 5 天，$\hat{c}_{\text{eval}} = 100\%$，但每单多承诺 5 天。两种情况下命题 2 都成立；命题 3 的可交换性却不成立，所以不能沿用其保证（Barber 等人）。

3. 整数日期

预计日期必须是整数。因为 Y 是整数，$Y \leq U \iff Y \leq \lfloor U \rfloor$，所以向下取整与连续边界覆盖完全相同的订单；最低 1 天的限制只会扩大覆盖。项目登记的规则是 $\max\{1, \lceil U \rceil\}$。它覆盖的订单包含 U 覆盖的订单，所以命题 2、3 中的下界对它同样成立。把 U 向上取整为 $\lceil U \rceil$，增加的天数小于一天。最低 1 天的限制是另一项调整，只会提高覆盖。

4. 回到 Olist

校准集有 $n = 17{,}056$ 笔订单，$k = 15{,}352$，所以 $k/n \approx 90.01\%$，$k/(n+1) \approx 90.00\%$。以线性模型为例，三个量分别是：

- 校准集上：登记的向上取整日期覆盖 91.19%，不低于 k/n，与命题 2 一致；独立重算第 k 个残差得到的平移量（6.1479 天）与冻结值相同；
- 可交换性下的保证：至少 $k/(n+1)$，但 C（2017 年 10–12 月）与评价期 E（2018 年 4–7 月）是否可交换，本身就是问题；
- 评价期上：19,950 笔订单的实际覆盖为 96.18%。

E 上的过覆盖提示，校准期与评价期之间的关系值得进一步检查。这个现象与配送时间变化、样本筛选及订单构成变化都可能相容。本说明没有做专门的可交换性检验，也不能分离这些因素的贡献。因此，我把它作为诊断线索，而不是对某一个原因的确认。此外，全部结论只适用于最终签收的单卖家订单。